TEMPLATE PARA ENTREGA DO PROJETO DA DISCIPLINA
Projeto em Business Intelligence e Analytics
Fase 2

Nome do estudante: Patricia Santos da Silva Kristem

1. Métricas para o negócio proposto (KPIs):

Foram definidas métricas estratégicas com base nos resultados da análise exploratória inicial com o objetivo de monitorar o comportamento da inadimplência e seus possíveis determinantes macroeconômicos.

As KPIs foram definidas com base nos resultados das análises estatísticas, contemplando indicadores descritivos, explicativos e preditivos. Essa estrutura permite não apenas monitorar o comportamento da inadimplência, mas também antecipar tendências e apoiar a tomada de decisão estratégica.

KPI	Descrição	Fórmula	Objetivo	Justificativa
1 - Taxa de inadimplência.	Percentual de operações de crédito em atraso no período.	$Inadimplência_t$	Monitorar o nível atual de risco de crédito	Variável principal do estudo, com forte persistência temporal e melhor capacidade preditiva
2 - Variação da Inadimplência	Mudança da inadimplência em relação ao período anterior.	$\Delta Inad = Inadt - Inadt - 1$	Identificar tendência de alta ou queda	Permite detectar aceleração ou desaceleração da inadimplência
3- índice de Persistência (AR1)	Permite detectar aceleração ou desaceleração da inadimplência	$\beta \text{ do modelo } AR(1) \text{ ou } \frac{Inad_t}{Inad_{t-1}}$	Medir a inércia da inadimplência	A análise mostrou que a inadimplência é fortemente autoregressiva
4 - Índice de Pressão Inflacionária (IPCA)	Índice de preços ao consumidor amplo	$IPCA_t$	Acompanhar pressão inflacionária	Variável relevante no contexto econômico, mas com baixa capacidade preditiva no modelo
5 - Indicador de Atividade Econômica (PIB)	Taxa de crescimento econômico	PIB_t	Avaliar atividade econômica	Série altamente volátil e pouco previsível, utilizada como indicador de contexto
6 - Taxa de Desocupação	Percentual da população economicamente ativa sem emprego.	$Desocupação_t$	Monitorar condições do mercado de trabalho	Apresenta alguma persistência, mas impacto limitado na previsão da inadimplência

2. Arquitetura da solução (ferramentas, pipeline com as fases, repositórios, dependências):

A solução proposta integra etapas de Business Intelligence e Analytics com o objetivo de coletar, tratar, analisar e apresentar indicadores relacionados à inadimplência e aos fatores macroeconômicos selecionados. A arquitetura foi estruturada para transformar dados brutos provenientes de fontes públicas em informações analíticas e visualizações gerenciais que apoiem a tomada de decisão.

A coleta de dados será realizada a partir de bases públicas oficiais, contemplando indicadores como taxa de inadimplência, taxa de desocupação, variação do PIB e variação do IPCA. Após a coleta, os dados passam por uma etapa de preparação, na qual são organizados, padronizados e consolidados em uma base única para análise. Nessa etapa são executados procedimentos de limpeza, ajuste de periodicidade, tratamento de inconsistências e estruturação temporal das variáveis.

Na camada de Business Intelligence serão feitas explorações descritivas e diagnósticas a fim de identificar a estrutura e comportamento dos dados durante o período selecionado, identificação de estacionariedade das séries temporais e existência de correlações entre as variáveis selecionadas. Para isso serão utilizadas bibliotecas de análise estatística e de visualização gráfica.

Na camada de Analytics, os dados agora compreendidos, serão preparados para compor um modelo de predição que for mais adequado. Para isso serão selecionadas as variáveis mais promissoras da camada exploratória anterior. Essa etapa visa ampliar a abordagem de BI ao incorporar métodos analíticos capazes de gerar previsões e apoiar decisões baseadas em evidências.

O GitHub será utilizado como repositório central do projeto, armazenando os códigos-fonte de tratamento e análise dos dados, além de documentação técnica, organização dos arquivos e registro do fluxo de desenvolvimento do projeto. Dessa forma, a solução garante rastreabilidade, reprodutibilidade e transparência no processo analítico.

Resumo das ferramentas	
Fontes de dados	Banco Central do Brasil (BCB) e Instituto Brasileiro de Geografia e Estatística (IBGE)
Coleta e Preparação	Google Colaboratory, Python, Bibliotecas: Pandas, Numpy
Análise e predição	Google Colaboratory, Python, Bibliotecas: Seaborn, Matplotlib, Scipy, Statsmodels
Visualização	Tableau
Repositório	GitHub

Pipeline (notebook script.ipynb):

1 – Coleta de dados no BCB e no SIDRA do IBGE
2 – Ajustes dados do BCB:
    2.1.Substituir vírgula por ponto,
    2.2.Data para formato “datetime”,
    2.3.Renomear colunas,
    2.4.Passar dados mensais para trimestrais.
3 – Ajustes nos dados do SIDRA:
    3.1.Seleção de colunas de interesse,

3.2.Ajuste do cabeçalho,
3.3.Ajuste do formato dos dados numéricos,
3.4.Substituição de códigos por rótulos intuitivos,
3.5.Datas para formato “datetime”,
3.6.Criação de novas colunas com cálculo de interesse,
3.7.Passar os dados que forem mensais para trimestrais.

4 – União dos 4 dataframes em um conjunto de dados final trimestral.

5 – Exportar.

6 – BI - Fase 1:

6.1.Definir o período como índice;
6.2.Verificar se está em ordem crescente;
6.3.Verificar a existência de valores nulos;
6.4.Exibir as estatísticas básicas (‘describe()’);
6.5.Plotar um gráfico de linhas;
6.6.Aplicar correlações de Pearson e Spearman;
6.7.Verificar estacionariedade;
6.8.Plotar gráficos de decomposição.

7 – BI – Fase 2:

7.1.Aplicar diferenciação no conjunto de dados;
7.2.Correlações de Pearson e Spearman nos dados já diferenciados;
7.3.Correlação de Pearson entre inadimplência e demais variáveis considerando 4 defasagens;
7.4.Aplicar teste de causalidade de Granger;

8 – Fase de Analytics:

8.1.Testar um modelo autorregressivo puro apenas com a variável da inadimplência;
8.2.Testar o mesmo modelo com lag1 da inadimplência e lag2 da desocupação;
8.3.Validação dos dois modelos testados;
8.4.Usar o melhor dos dois modelos para fazer previsões;
8.5.Definir uma função para 4 períodos à frente;
8.6.Criar cenários para a taxa de desemprego (base, pessimista, otimista);
8.7.Plotar um gráfico interativo da taxa de inadimplência histórica + previsão.

9 – Expotar o df com as previsões nos forrmatos .csv e .xlsx

10 – Ajustes no excel:

10.1.Abrir o conjunto de dados ***inadimplencia_dashboard*** no Excel;

10.2.Renomear a planilha para “inadimplência hist e prev” para diferenciar da outra base de dados no Tableau.

10.3.Ajustar o formato da coluna “valor” para “Número”

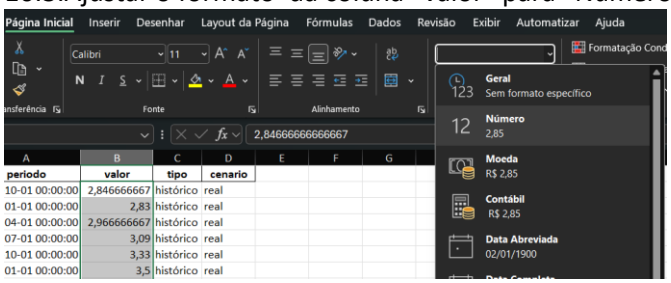

10.4.Selecionar a coluna “período”, do título até a última célula de dado real (1-46) e copiar.

10.5.Colar no conjunto de dados “***Conjunto Final Unificado – Trimestral.”***

A	B	C	D	E	F
trimestre	txa_variacao_pib	media_inadimplencia	taxa_desocupados	media_ipca	periodo
2014Q4	0,50	2,85	6,56	0,65	2014-10-01 00:00:00
2015Q1	-0,70	2,83	8,02	1,26	2015-01-01 00:00:00
2015Q2	-1,30	2,97	8,41	0,75	2015-04-01 00:00:00
2015Q3	-2,20	3,09	9,00	0,46	2015-07-01 00:00:00
2015Q4	-3,50	3,33	9,06	0,93	2015-10-01 00:00:00
2016Q1	-4,40	3,50	11,04	0,87	2016-01-01 00:00:00
2016Q2	-4,50	3,63	11,42	0,58	2016-04-01 00:00:00
2016Q3	-4,10	3,63	11,90	0,35	2016-07-01 00:00:00
2016Q4	-3,30	3,78	12,13	0,25	2016-10-01 00:00:00
2017Q1	-1,90	3,78	13,85	0,32	2017-01-01 00:00:00

10.6.Excluir a coluna “Trimestre” do “Conjunto Final Unificado – Trimestral”.

10.7.Renomear a planilha para “todas as variáveis” para facilitar a diferenciação com outra base de dados no Tableau.

10.8.Salvar e fechar ambos os arquivos.

11 – No Tableau, importar as duas bases de dados e relacioná-las pela coluna período para criar as visualizações.

Diagrama da arquitetura utilizada:

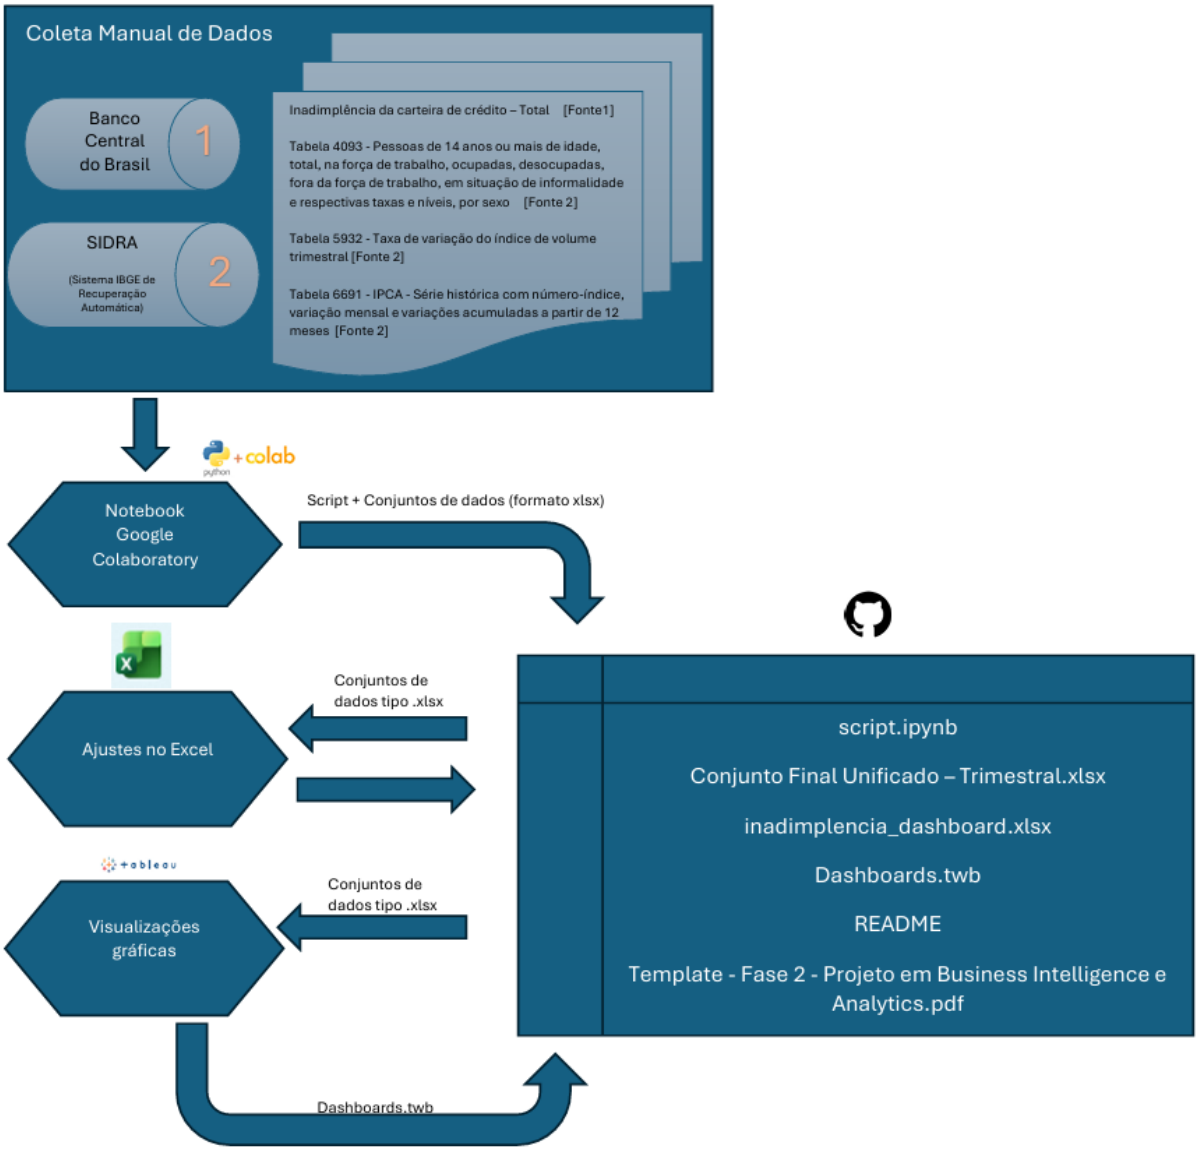

3. Solução de BI:

O script com as etapas de BI e Analytics está disponibilizado no repositório GitHub.

3.1 – Coleta e transformação:

Os dados foram coletados do Banco Central do Brasil (BCB) e das tabelas do SIDRA do IBGE. Essa coleta é feita através de algoritmo usando linguagem Python e a biblioteca Pandas para que sejam sempre coletados os dados mais atuais disponíveis nas plataformas citadas.

Os dados de inadimplência e do IPCA são divulgados mensalmente. A fim de manter todas as bases de dados padronizadas no mesmo período foi feita uma média por trimestre e, assim, os dados mensais passaram a ser trimestrais.

```
1 df_inadimplencia_trimestral.head()
```

	trimestre	media_inadimplencia
0	2011Q1	3.170000
1	2011Q2	3.310000
2	2011Q3	3.443333
3	2011Q4	3.566667
4	2012Q1	3.680000

```
1 df_ipca_trimestral.head()
```

	trimestre	media_ipca
0	2014Q4	0.645000
1	2015Q1	1.260000
2	2015Q2	0.746667
3	2015Q3	0.460000
4	2015Q4	0.930000

Além dessa transformação foram realizados ajustes em tipos de dados (ex.: ‘object’ → ‘float’), padronização do nome de colunas (ex.: ‘Mês (código)’ → ‘trimestre’), seleção de colunas de interesse.

3.2 – Fase exploratória

Visualização de métricas básicas demonstra grande amplitude dos dados nas variáveis relacionadas ao PIB e ao desemprego.

	txa_variacao_pib	media_inadimplencia	taxa_desocupados	media_ipca
count	45.000000	45.000000	45.000000	45.000000
mean	0.906667	3.135407	10.309556	0.461148
std	2.712463	0.467692	2.822400	0.336008
min	-4.500000	2.166667	5.070000	-0.443333
25%	-1.300000	2.950000	7.940000	0.236667
50%	1.700000	3.140000	11.140000	0.413333
75%	3.000000	3.496667	12.510000	0.676667
max	4.800000	4.023333	14.910000	1.260000

Gráfico de linhas, que demonstra algum comportamento aparentemente oposto entre inadimplência e desemprego a partir de 2020.

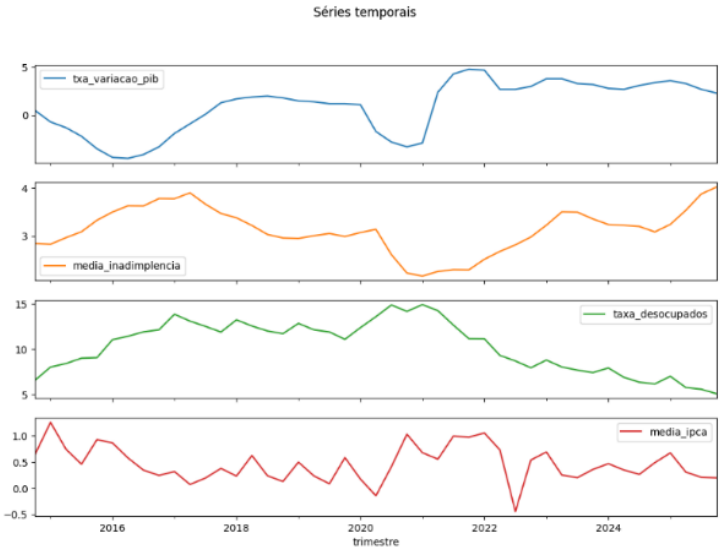

Correlações foram feitas, inicialmente sem considerar a defasagem dos dados.

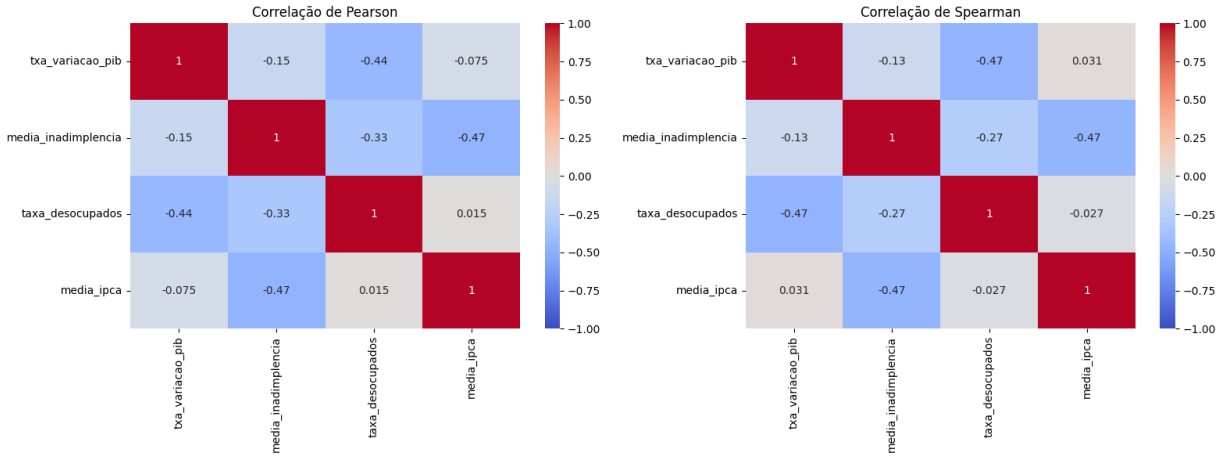

Algumas correlações negativas aparecem, entre elas a taxa de desocupação X taxa de inadimplência no valor negativo de -0,27 a -0,33.

Relações mais significativas aparecem entre a taxa de variação do PIB e a taxa de desocupação (-0,44 a -0,47) e a taxa de inadimplência e a taxa de variação do IPCA (-0,47).

São relações fracas a moderadas que serão testadas posteriormente considerando a defasagem dos dados, pois nesse cenário é provável que uma variável não tenha impacto imediato em outra, mas com certa defasagem de tempo.

Verificação da estacionariedade das séries temporais:

```
====== TESTE DE ESTACIONARIEDADE ======

p-value < 0.05 → estacionária ✓
p-value > 0.05 → não estacionária X

media_inadimplencia: p-value = 0.2652
txa_variacao_pib: p-value = 0.1017
taxa_desocupados: p-value = 0.9451
media_ipca: p-value = 0.1140
```

As séries precisam ser diferenciadas para que se tornem estacionárias, a fim de eliminar o efeito de tendências comuns e captar as relações entre **variações** ao longo do tempo. Após isso, será feita nova correlação. Assim, reduz-se o risco de correlações espúrias permitindo uma análise mais consistente da dinâmica temporal entre as variáveis.

Gráficos de decomposição das séries:

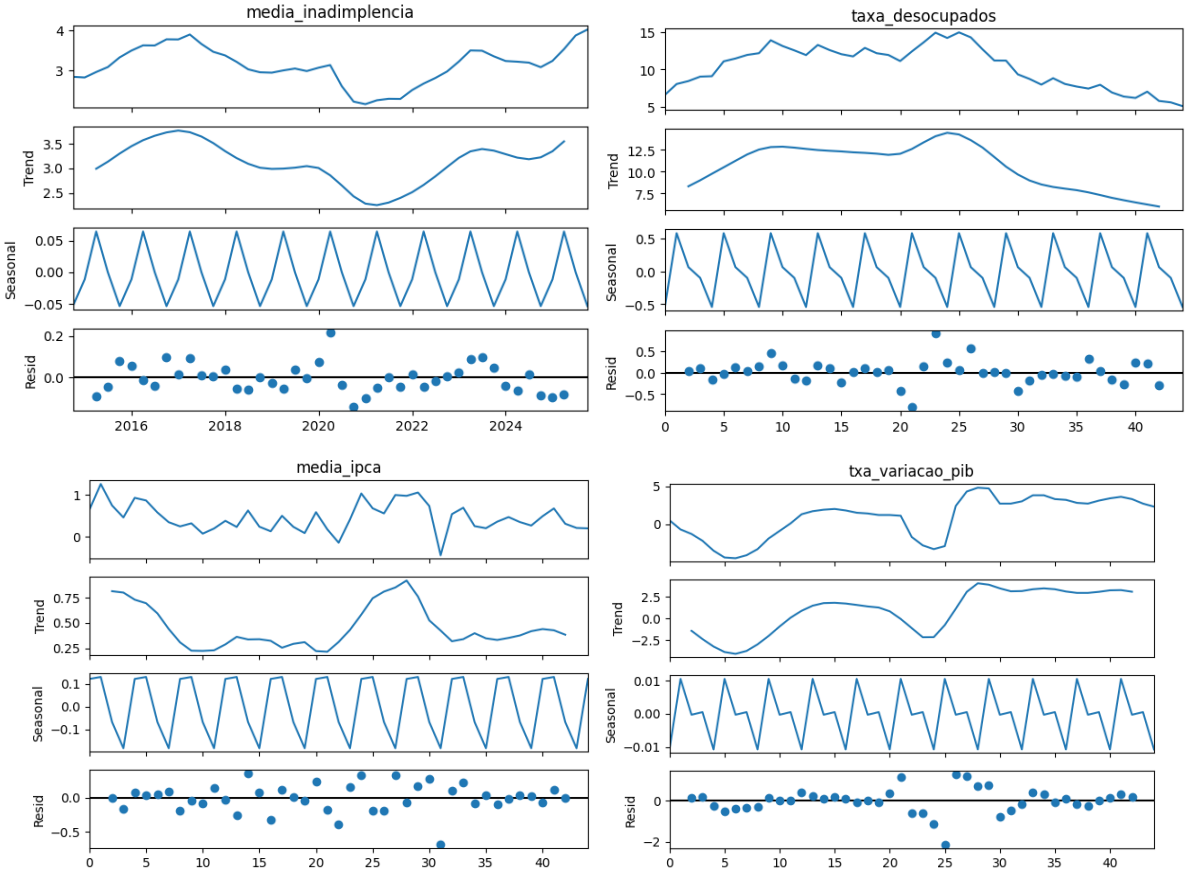

No caso da inadimplência a série é dominada pela tendência de longo prazo, sazonalidade anual fraca mas consistente. O período 2020–2021 foi claramente atípico, e há trajetória recente de alta na tendência.

O desemprego tem um comportamento estrutural bem definido, com a tendência de queda robusta e sustentada. A sazonalidade é mais relevante do que na inadimplência. O choque pandêmico é bastante visível nos resíduos. A trajetória atual de queda é consistente.

3.3 – Ajustes e retestes:

- Tornar a série estacionária removendo tendências e sazonalidade. Para isso será feita a diferenciação.
- Implementar defasagens: As correlações do desemprego com a taxa de inadimplência são contraintuitivas. É provável que haja defasagens nos dados, pois as consequências do aumento do desemprego podem demorar meses para aparecer na inadimplência.

Diferenciação:

Foi necessária apenas 01 diferenciação para que as séries se tornassem estacionárias:

```
====== TESTE DE ESTACIONARIEDADE ======

p-value < 0.05 → estacionária ✓
p-value > 0.05 → não estacionária X

txa_variacao_pib: p-value = 0.0040
media_inadimplencia: p-value = 0.0097
taxa_desocupados: p-value = 0.0216
media_ipca: p-value = 0.0000
```

Agora, com todas as séries estacionárias as correlações serão refeitas:

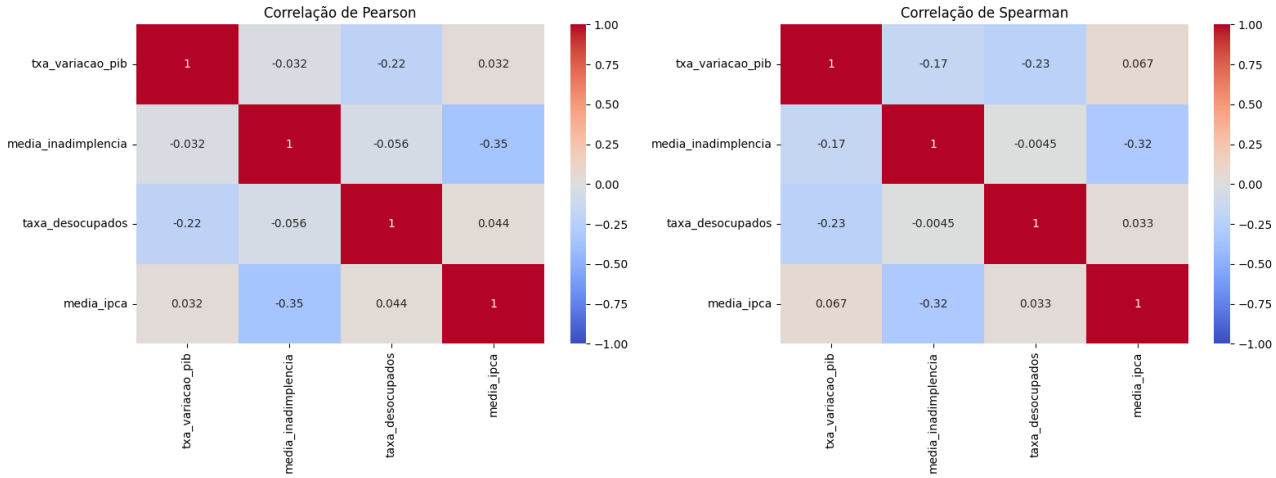

Correlação das variáveis com a inadimplência após diferenciação, **considerando as defasagens**:

Defasagem (lag)	Desemprego	Variação do IPCA	Variação do PIB
1	-0.0571161505889534	-0.02573960711325096	0.10756583265092827
2	-0.3038174767676741	0.16734720350207066	0.01194218724278406
3	-0.17108897908265122	-0.14317468996803803	-0.0382892370149817

4	-0.06958493792896242	-0.07416874543831381	-0.10061086466016804

A correlação linear mais expressiva (-0,30) ocorre dois períodos à frente (lag 2) entre a taxa de desemprego e taxa de inadimplência. Essa é uma correlação negativa fraca (no máximo moderada dependendo da escala seguida, que pode variar um pouco dependendo do autor).

Teste de causalidade de Granger:

Nesse teste a causalidade tem o sentido de precedência temporal, ou seja, com o teste podemos avaliar se uma variável X precede temporalmente uma variável Y. A interpretação é a seguinte:

- **Hipótese nula:** a série temporal X não Granger-causa a série Y
- **Hipótese alternativa:** a série temporal X Granger-causa a série Y

Os resultados são baseados no p-valor. Se o p-valor for menor que um nível de significância (como 0,05), rejeitamos a hipótese nula e concluímos que há causalidade.

```
Granger Causality
number of lags (no zero) 1
ssr based F test:         F=0.0520  , p=0.8207  , df_denom=40, df_num=1
ssr based chi2 test:   chi2=0.0559  , p=0.8130  , df=1
likelihood ratio test: chi2=0.0559  , p=0.8131  , df=1
parameter F test:         F=0.0520  , p=0.8207  , df_denom=40, df_num=1

Granger Causality
number of lags (no zero) 2
ssr based F test:         F=2.4816  , p=0.0974  , df_denom=37, df_num=2
ssr based chi2 test:   chi2=5.6339  , p=0.0598  , df=2
likelihood ratio test: chi2=5.2867  , p=0.0711  , df=2
parameter F test:         F=2.4816  , p=0.0974  , df_denom=37, df_num=2

Granger Causality
number of lags (no zero) 3
ssr based F test:         F=1.7624  , p=0.1729  , df_denom=34, df_num=3
ssr based chi2 test:   chi2=6.3757  , p=0.0947  , df=3
likelihood ratio test: chi2=5.9260  , p=0.1153  , df=3
parameter F test:         F=1.7624  , p=0.1729  , df_denom=34, df_num=3

Granger Causality
number of lags (no zero) 4
ssr based F test:         F=1.4272  , p=0.2483  , df_denom=31, df_num=4
ssr based chi2 test:   chi2=7.3659  , p=0.1178  , df=4
likelihood ratio test: chi2=6.7610  , p=0.1491  , df=4
parameter F test:         F=1.4272  , p=0.2483  , df_denom=31, df_num=4
```

Nesse estudo, em nenhuma defasagem os p-valores ficaram abaixo do nível de significância convencional de 5% ($p < 0,05$). Portanto, **não se rejeita H_0 em nenhum caso**. No lag 2, o p-valor do teste F ficou em 0,097 e o chi² em 0,060 (ambos marginalmente próximos de 10%), o que sugere uma leve evidência de causalidade, mas insuficiente pelos critérios convencionais. Já nas demais defasagens, os p-valores são bem altos, indicando ausência de relação preditiva. Portanto, com base nesses resultados, **não há evidência estatística suficiente** de que o desemprego causa Granger a inadimplência no período analisado.

3.4 – Testes autorregressivos:

Para finalizar, foi aplicado um modelo autorregressivo na variável taxa de inadimplência (primeiro com 2 e depois com1 lag). E depois o mesmo teste com inadimplência e a lag 2 da variável taxa de desemprego.

02 defasagens:

```
                            AutoReg Model Results
==============================================================================
Dep. Variable:     media_inadimplencia   No. Observations:                   44
Model:                     AutoReg(2)   Log Likelihood                  22.215
Method:               Conditional MLE   S.D. of innovations              0.143
Date:                Wed, 08 Apr 2026   AIC                            -36.430
Time:                        17:49:12   BIC                            -29.479
Sample:                    07-01-2015   HQIC                           -33.882
                         - 10-01-2025
=======================================================================================
                          coef    std err          z      P>|z|      [0.025      0.975]
---------------------------------------------------------------------------------------
const                   0.0115      0.022      0.516      0.606      -0.032       0.055
media_inadimplencia.L1  0.6724      0.151      4.465      0.000       0.377       0.968
media_inadimplencia.L2 -0.1865      0.157     -1.190      0.234      -0.494       0.121
                                    Roots
=============================================================================
                  Real          Imaginary           Modulus         Frequency
-----------------------------------------------------------------------------
AR.1            1.8030           -1.4532j            2.3157           -0.1080
AR.2            1.8030           +1.4532j            2.3157            0.1080
-----------------------------------------------------------------------------
```

AIC e BIC: Menor valor, melhor.

01 defasagem:

```
                            AutoReg Model Results
==============================================================================
Dep. Variable:     media_inadimplencia   No. Observations:                   44
Model:                     AutoReg(1)   Log Likelihood                  22.107
Method:               Conditional MLE   S.D. of innovations              0.145
Date:                Wed, 08 Apr 2026   AIC                            -38.213
Time:                        17:54:03   BIC                            -32.930
Sample:                    04-01-2015   HQIC                           -36.265
                         - 10-01-2025
=======================================================================================
                          coef    std err          z      P>|z|      [0.025      0.975]
---------------------------------------------------------------------------------------
const                   0.0142      0.022      0.635      0.525      -0.030       0.058
media_inadimplencia.L1  0.5677      0.126      4.490      0.000       0.320       0.816
                                    Roots
=============================================================================
                  Real          Imaginary           Modulus         Frequency
-----------------------------------------------------------------------------
AR.1            1.7614           +0.0000j            1.7614            0.0000
-----------------------------------------------------------------------------
```

A inadimplência depende basicamente do próprio passado imediato. E adicionar mais lags não melhorou o modelo, portanto AR.1 é melhor.

Testando inadimplência com desemprego o modelo melhorou um pouco:

```
                            OLS Regression Results
==============================================================================
Dep. Variable:     media_inadimplencia   R-squared:                       0.401
Model:                             OLS   Adj. R-squared:                  0.370
Method:                  Least Squares   F-statistic:                     13.06
Date:                 Wed, 08 Apr 2026   Prob (F-statistic):           4.56e-05
Time:                         18:15:58   Log-Likelihood:                 23.983
No. Observations:                   42   AIC:                            -41.97
Df Residuals:                       39   BIC:                            -36.75
Df Model:                            2
Covariance Type:             nonrobust
==========================================================================================
                             coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------------------
const                      0.0103      0.022      0.466      0.644      -0.034       0.055
inad_lag1                  0.5570      0.124      4.484      0.000       0.306       0.808
taxa_desocupados_lag2     -0.0513      0.023     -2.203      0.034      -0.098      -0.004
==============================================================================
Omnibus:                       14.837   Durbin-Watson:                   1.770
Prob(Omnibus):                  0.001   Jarque-Bera (JB):               19.581
Skew:                          -1.074   Prob(JB):                     5.60e-05
Kurtosis:                       5.564   Cond. No.                         5.69
==============================================================================
```

3.5 – Conclusão:

Durante análise dos dados desse conjunto, deve-se levar em consideração as defasagens de tempo (lags) para melhor interpretar sua relevância.

Variação do PIB e do IPCA não têm poder explicativo relevante para a inadimplência no curto prazo.

A evolução da taxa de desocupação possui uma correlação negativa fraca a moderada com a taxa de inadimplência dois períodos à frente. Ou seja, quando a taxa de desemprego diminui a taxa de inadimplência tende a aumentar 2 trimestres depois.

Sabendo disso, podemos iniciar uma fase de Analytics e usar um modelo autorregressivo entre as variáveis inadimplência (lag 1) e desocupação (lag 2).

A empresa pode utilizar o modelo para antecipar movimentos da inadimplência com base na evolução do desemprego, permitindo ajustes proativos na concessão de crédito e na gestão de risco, reduzindo perdas e aumentando a eficiência operacional.

Analytics:

Um gráfico do modelo preditivo foi adicionado ao dashboard no Tableau considerando diferentes análises de cenário para a taxa de desocupação (base, otimista, pessimista).

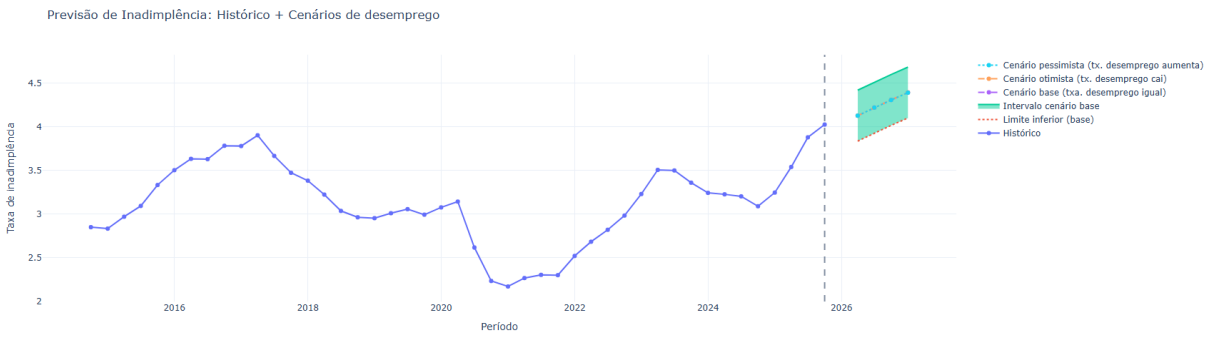

(Gráfico do notebook “script”)

Link do repositório no GitHub

https://github.com/PatiEstudante/OProjetoFinal-202601